Fase 1 — Documentación y Diseño Técnico

Índice

1. Título del proyecto e integrantes
    - 1.1 Título del proyecto
    - 1.2 Descripción breve
    - 1.3 Equipo de desarrollo
    - 1.4 Contexto académico
2. Resumen ejecutivo
3. Descripción funcional del sistema
    - 3.1 Perfil del usuario
    - 3.2 Flujo de uso del sistema
    - 3.3 Datos de entrada
    - 3.4 Resultado obtenido
    - 3.5 Advertencia sobre el alcance del sistema
    - 3.6 Limitaciones del sistema
4. Alcance definitivo (IN / OUT)
    - 4.1 Dentro del alcance (IN)
    - 4.2 Fuera del alcance (OUT)
5. Arquitectura del sistema
    - 5.1 Diagrama de arquitectura
    - 5.2 Frontend
    - 5.3 Backend
    - 5.4 Base de datos
    - 5.5 Servicios de Machine Learning
    - 5.6 Pipeline de datos
    - 5.7 Dashboards y visualización
    - 5.8 Otros servicios
    - 5.9 Justificación del enfoque de modelado
6. Tecnologías seleccionadas
    - 6.1 Capa de datos
    - 6.2 Capa de modelado
    - 6.3 Capa de presentación
    - 6.4 Infraestructura y reproducibilidad
    - 6.5 Consideraciones de diseño arquitectónico
    - 6.6 Tabla resumen de tecnologías seleccionadas
7. Modelo de datos

- 7.1 Esquema lógico del dataset (equivalente a ER)
- 7.2 Entidades y relaciones (modelo equivalente)
- 7.3 Campos principales y tipología
- 7.4 Claves y restricciones
- 7.5 Diccionario de variables

8. Datos

- 8.1 Fuente y licencia
- 8.2 Naturaleza y tipología de los datos
- 8.3 Volumen y frecuencia
- 8.4 Calidad esperada
- 8.5 Riesgos asociados a los datos
- 8.6 Clasificación del origen de los datos

9. Ética, legalidad y accesibilidad

- 9.1 Datos personales y GDPR
- 9.2 Riesgos éticos del uso de modelos predictivos
- 9.3 Medidas de mitigación
- 9.4 Accesibilidad digital

10. Backlog inicial

- 10.1 Alta prioridad (Historias 1–6)
- 10.2 Prioridad media (Historias 7–9)
- 10.3 Prioridad baja (Historias 10–12)

11. Plan de trabajo

- 11.1 Cronograma por semanas
- 11.2 Hitos principales
- 11.3 Dependencias técnicas
- 11.4 Reparto de responsabilidades
- 11.5 Riesgos técnicos vinculados al plan

12. Estrategia de desarrollo

- 12.1 Modelo de ciclo de vida
- 12.2 Flujo Git
- 12.3 Integración del código
- 12.4 Validación funcional
- 12.5 Testing básico

13. Riesgos técnicos actualizados

- Tabla de riesgos: sobreajuste, desbalance de clases, dependencia del dataset, deriva del modelo, integración y reproducibilidad

14. Repositorio del proyecto

---

1. Título del proyecto e integrantes

1.1 Título del proyecto

GlucoCheck: Sistema de Clasificación del Riesgo de Diabetes Tipo 2 mediante Técnicas de Big Data e Inteligencia Artificial

1.2 Descripción breve

GlucoCheck es un proyecto académico enmarcado en el ámbito del Big Data y la Inteligencia Artificial, cuyo objetivo es diseñar y desarrollar un sistema capaz de clasificar el nivel de riesgo de diabetes tipo 2 en individuos a partir de variables clínicas y biométricas. El sistema integra un pipeline de procesamiento de datos, modelos de aprendizaje automático supervisado y una capa de visualización interactiva orientada a la exploración analítica de los resultados.

El proyecto responde a una necesidad real del sector sanitario: la identificación temprana de perfiles de riesgo asociados a la diabetes tipo 2, una enfermedad crónica de alta prevalencia a nivel mundial. GlucoCheck no sustituye el diagnóstico médico ni realiza monitorización continua de pacientes; su alcance se limita a la clasificación del riesgo a partir de datos estáticos, proporcionando una herramienta de apoyo a la toma de decisiones basada en evidencia analítica.

1.3 Equipo de desarrollo

El equipo está compuesto por cuatro integrantes, cada uno con un rol especializado que cubre las áreas técnicas clave del proyecto:

Integrante	Rol	Responsabilidades principales
Markel	Data Engineer	Diseño e implementación del pipeline de datos, ingesta, transformación (ETL/ELT) y gestión del almacenamiento en el Data Lake / Data Warehouse.
Steven	ML Engineer	Selección, entrenamiento, evaluación y despliegue de los modelos de Machine Learning para la predicción del riesgo de diabetes.
Juan Carlos	DevOps	Configuración de la infraestructura, gestión de contenedores, integración y despliegue continuo (CI/CD) y monitorización técnica y mantenimiento de la infraestructura.
Miguel Ángel	Frontend / BI	Desarrollo de la interfaz de usuario, diseño de dashboards interactivos y visualización de los resultados analíticos mediante herramientas de BI.

1.4 Contexto académico

Este proyecto se desarrolla como parte del módulo de Proyecto del programa de **Big Data e Inteligencia Artificial**, con el objetivo de aplicar de forma integrada las competencias adquiridas a lo largo del programa en un caso de uso real y socialmente relevante.

---

2. Resumen ejecutivo

La diabetes tipo 2 constituye un reto relevante de salud pública debido a su elevada prevalencia y a las complicaciones asociadas a un diagnóstico tardío. En este contexto, la identificación temprana de perfiles de riesgo puede apoyar estrategias de prevención y priorización de evaluaciones clínicas.

GlucoCheck propone el diseño de un sistema académico de clasificación del riesgo de diabetes tipo 2 basado en técnicas de Big Data e Inteligencia Artificial. A partir de variables clínicas y biométricas estáticas introducidas por el usuario, el sistema aplica un modelo de aprendizaje supervisado que estima una probabilidad y la categoriza en niveles de riesgo interpretables. El resultado se presenta mediante una interfaz web clara, orientada a la exploración analítica.

El valor del proyecto reside en demostrar la viabilidad técnica y metodológica de integrar un pipeline de datos, un proceso de validación del modelo y una capa de visualización reproducible dentro de un marco ético y legal delimitado. El sistema no sustituye el diagnóstico médico, no emite recomendaciones terapéuticas, no realiza monitorización continua y no trata datos personales reales.

3. Descripción funcional del sistema

3.1 Perfil del usuario

GlucoCheck está orientado a dos perfiles de usuario principales. En primer lugar, profesionales del ámbito sanitario o de la salud pública que deseen explorar patrones de riesgo en conjuntos de datos clínicos con fines analíticos o de investigación. En segundo lugar, usuarios con formación técnica o científica —como estudiantes, investigadores o analistas de datos— interesados en aplicar modelos de clasificación sobre variables biométricas. En ningún caso el sistema está dirigido a pacientes sin formación adecuada para interpretar sus resultados, dado que no emite diagnósticos médicos ni recomendaciones terapéuticas.

3.2 Flujo de uso del sistema

El sistema sigue un flujo de interacción lineal y estructurado en las siguientes etapas:

1. **Acceso a la interfaz**: el usuario accede a la aplicación web a través de un navegador, sin necesidad de instalación local.
2. **Introducción de datos**: el usuario introduce manualmente un conjunto de variables clínicas y biométricas correspondientes a un individuo.
3. **Envío y procesamiento**: el sistema recibe los datos, los valida y los procesa aplicando el modelo de clasificación previamente entrenado.
4. **Visualización del resultado**: el sistema devuelve una clasificación del nivel de riesgo de diabetes tipo 2, acompañada de una representación visual del resultado.
5. **Consulta de información complementaria**: el usuario puede acceder a una vista analítica con información contextual sobre las variables introducidas y su peso relativo en la clasificación.

3.3 Datos de entrada

El sistema requiere la introducción de las siguientes variables para generar una clasificación:

- Nivel de glucosa en ayunas
- Índice de masa corporal (IMC)
- Presión arterial diastólica
- Grosor del pliegue cutáneo tricipital

- Nivel de insulina sérica
- Edad
- Número de embarazos (aplicable según perfil)
- Función de pedigrí de diabetes (antecedentes familiares)

Estas variables corresponden a las recogidas en el conjunto de datos de referencia utilizado para el entrenamiento del modelo, por lo que el sistema no admite, en su versión actual, variables adicionales no contempladas en dicho conjunto.

3.4 Resultado obtenido

El sistema devuelve una clasificación del nivel de riesgo de diabetes tipo 2 a partir de la probabilidad estimada por el modelo. Aplicando umbrales definidos sobre dicha probabilidad, el resultado se categoriza en uno de los tres niveles siguientes:

- **Riesgo bajo** *(verde)*: la probabilidad estimada se sitúa por debajo del umbral inferior. Las variables introducidas no presentan una combinación de indicadores estadísticamente relevante para la clasificación positiva.
- **Riesgo moderado** *(amarillo)*: la probabilidad estimada se sitúa entre los umbrales inferior y superior. Las variables introducidas presentan algunos indicadores asociados al riesgo, sin alcanzar el nivel de certeza estadística del nivel alto.
- **Riesgo alto** *(rojo)*: la probabilidad estimada supera el umbral superior. Las variables introducidas presentan una combinación de indicadores estadísticamente asociada a un perfil de riesgo elevado.

Los valores concretos de los umbrales se determinarán durante la fase de entrenamiento y evaluación del modelo, atendiendo a criterios de rendimiento como la sensibilidad y la especificidad. El resultado se acompaña de una representación visual y de los valores introducidos, sin que el sistema emita ningún tipo de recomendación clínica o terapéutica.

La definición definitiva de los umbrales se realizará durante la fase de validación del modelo, empleando métricas de evaluación estándar como la sensibilidad, la especificidad y el análisis de la curva ROC. Dado el contexto clínico del problema, se priorizará la minimización de falsos negativos en el nivel de riesgo alto, por cuanto una clasificación errónea en este estrato tiene mayor relevancia desde el punto de vista sanitario. La estrategia de umbralización buscará, en último término, un equilibrio entre la capacidad discriminativa del modelo y la utilidad interpretativa del resultado para el usuario.

3.5 Advertencia sobre el alcance del sistema

> **Aviso importante**: GlucoCheck es una herramienta de apoyo analítico con fines académicos. Los resultados obtenidos no constituyen un diagnóstico médico, no sustituyen la valoración de un profesional de la salud y no deben ser utilizados para tomar decisiones clínicas. Ante cualquier duda sobre el estado de salud, el usuario debe consultar a un médico.

3.6 Limitaciones del sistema

- El modelo ha sido entrenado sobre un conjunto de datos específico y puede no ser representativo de todas las poblaciones.
- El sistema no contempla variables contextuales como hábitos de vida, medicación activa o historial clínico completo.

- No realiza seguimiento longitudinal ni comparación entre consultas sucesivas.
- Los resultados pueden verse afectados por valores atípicos o datos incompletos introducidos por el usuario.
- La estabilidad y generalización de los umbrales definidos dependen de la calidad, tamaño y representatividad del conjunto de datos utilizado para el entrenamiento y validación del modelo. Cambios en la distribución poblacional o en el perfil clínico de los individuos podrían requerir una recalibración periódica del sistema para mantener su validez predictiva.

4. Alcance definitivo (IN / OUT)

El presente apartado delimita de forma explícita el alcance funcional del sistema GlucoCheck, distinguiendo entre aquello que el sistema contempla y lo que queda fuera de su ámbito de actuación.

4.1 Dentro del alcance (IN)

- Clasificación del nivel de riesgo de diabetes tipo 2 a partir de un conjunto de variables clínicas y biométricas previamente definidas y acotadas.
- Operación sobre datos estáticos introducidos manualmente por el usuario a través de la interfaz web, sin conexión a fuentes de datos externas.
- Estimación de la probabilidad de riesgo mediante un modelo de clasificación supervisada y su categorización en tres niveles: bajo, moderado y alto.
- Presentación del resultado al usuario mediante una interfaz web con representación visual interpretativa.

4.2 Fuera del alcance (OUT)

- El sistema **no realiza diagnóstico médico** de ningún tipo, ni en sentido clínico ni legal.
- El sistema **no sustituye la valoración profesional** de un médico u otro profesional sanitario habilitado.
- El sistema **no accede a historias clínicas reales** ni a datos provenientes de sistemas de información sanitaria o fuentes en tiempo real.
- El sistema **no realiza monitorización longitudinal** de pacientes ni permite el seguimiento temporal de un mismo individuo.
- El sistema **no admite variables adicionales** no contempladas en el conjunto de datos de entrenamiento, ni generaliza a perfiles clínicos fuera de dicho dominio.
- El sistema **no toma decisiones automatizadas** sobre tratamientos, intervenciones clínicas o derivaciones asistenciales.

5. Arquitectura del sistema

La arquitectura de GlucoCheck se define bajo un enfoque modular por capas, separando claramente los componentes de datos, modelado y presentación. Esta estructura favorece la mantenibilidad, la trazabilidad y la coherencia con el alcance académico definido.

5.1 Diagrama de arquitectura

Se incorpora un diagrama de alto nivel que representa la interacción entre los distintos componentes del sistema: capa de datos, pipeline de procesamiento, modelo de clasificación y capa de presentación. El diagrama refleja el flujo unidireccional de datos desde su entrada hasta la generación del resultado de clasificación.

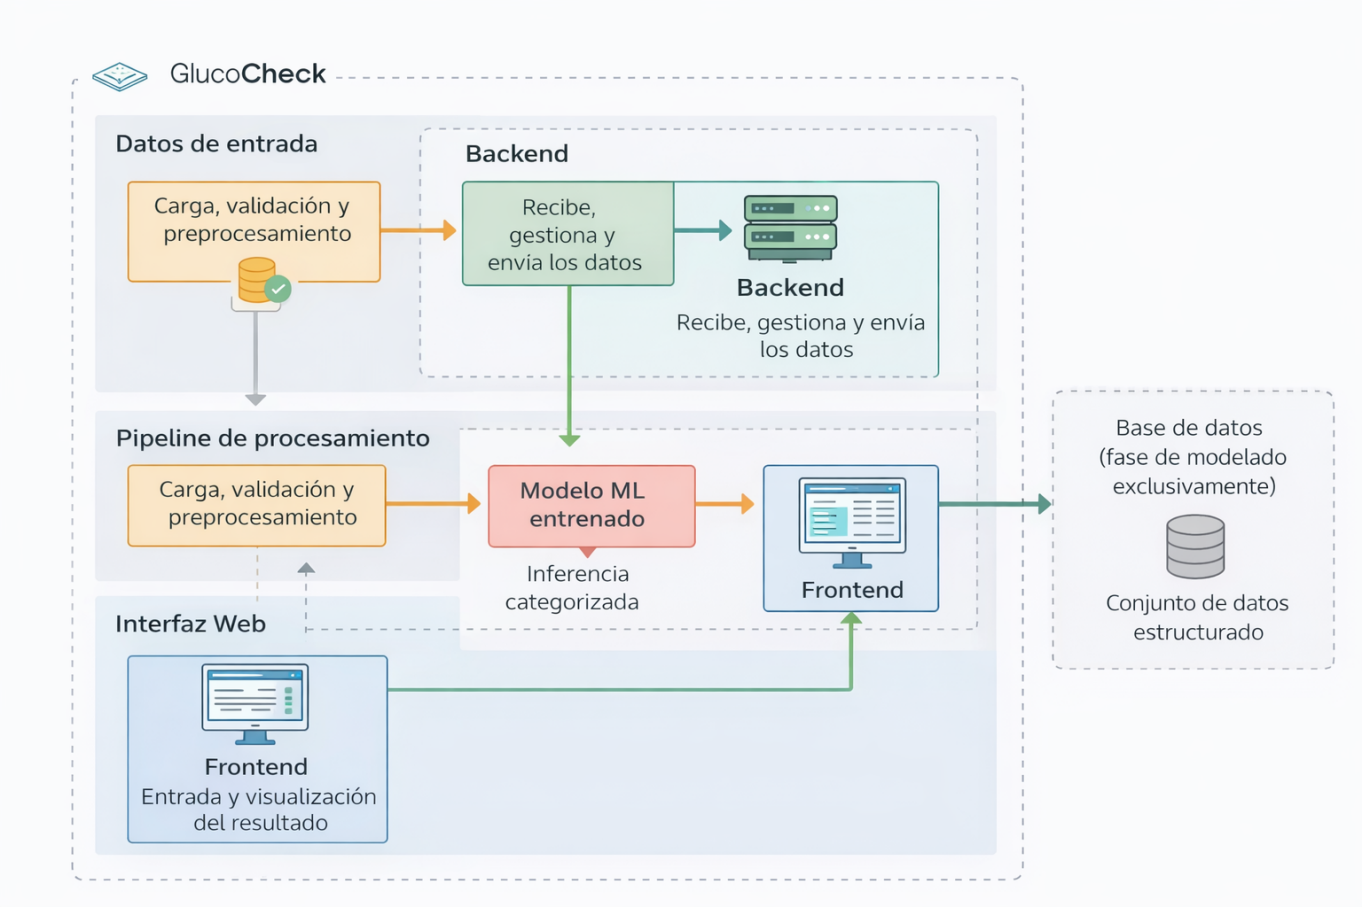

5.2 Frontend

La capa de presentación consiste en una aplicación web ligera que permite la introducción manual de variables clínicas y biométricas, así como la visualización del resultado de clasificación. Esta capa es responsable de la validación básica de entradas y de la comunicación del resultado de forma comprensible, sin realizar procesamiento analítico complejo.

5.3 Backend

El backend actúa como intermediario entre la interfaz de usuario y el modelo entrenado. Gestiona la recepción de los datos introducidos, ejecuta la inferencia mediante el modelo previamente serializado y devuelve el resultado categorizado a la capa de presentación.

5.4 Base de datos

El sistema no incorpora una base de datos persistente para almacenamiento de información de usuarios, en coherencia con el carácter estático y académico del proyecto. El conjunto de datos utilizado para entrenamiento se gestiona como recurso estructurado durante la fase de modelado, sin almacenamiento operativo de datos personales.

5.5 Servicios de Machine Learning

El componente de Machine Learning se basa en un modelo de clasificación supervisada entrenado previamente sobre el dataset público seleccionado. Este modelo estima la probabilidad de pertenencia a una categoría de riesgo y aplica los umbrales definidos para su categorización final.

5.6 Pipeline de datos

El pipeline de datos incluye las etapas de carga, validación, preprocesamiento y preparación de variables necesarias para el entrenamiento del modelo. Estas transformaciones garantizan la coherencia entre los datos utilizados en entrenamiento y los introducidos durante la inferencia.

5.7 Dashboards y visualización

La visualización de resultados se integra en la propia interfaz web mediante representaciones interpretativas que facilitan la comprensión del nivel de riesgo asignado, evitando representaciones ambiguas o potencialmente engañosas.

5.8 Otros servicios

No se contemplan servicios externos adicionales, integraciones con sistemas clínicos ni procesamiento en tiempo real. El sistema opera de forma autónoma dentro del entorno académico definido.

5.9 Justificación del enfoque de modelado

La elección del paradigma de aprendizaje supervisado para el componente de modelado de GlucoCheck responde a las características intrínsecas del problema y del conjunto de datos disponible. El dataset utilizado incluye una variable objetivo previamente etiquetada que indica la presencia o ausencia de diabetes tipo 2 en cada registro, lo que hace viable y metodológicamente adecuado el uso de algoritmos de clasificación supervisada. El objetivo del sistema no es descubrir agrupaciones o patrones latentes en los datos —tarea propia de los métodos no supervisados—, sino estimar la probabilidad de que un individuo pertenezca a una categoría de riesgo definida con antelación.

Una ventaja fundamental del enfoque supervisado en este contexto es la posibilidad de evaluar el rendimiento del modelo de forma objetiva, mediante métricas contrastadas como la sensibilidad, la especificidad, el área bajo la curva ROC u otras medidas de discriminación clínicamente interpretables. Esta capacidad de validación frente a una referencia conocida resulta esencial para justificar la utilidad del sistema como herramienta de apoyo analítico.

Los métodos no supervisados podrían tener un valor exploratorio en fases previas de análisis —por ejemplo, para identificar subgrupos poblacionales en los datos—, pero no permiten validar directamente la capacidad predictiva del sistema frente a una etiqueta clínica de referencia. Por este motivo, se descartan como enfoque principal del componente de clasificación, sin perjuicio de que puedan emplearse de forma auxiliar en etapas de análisis exploratorio de datos.

6. Tecnologías seleccionadas

La selección de tecnologías para GlucoCheck responde a criterios de adecuación al problema, madurez del ecosistema, reproducibilidad del entorno y coherencia con el alcance académico del proyecto. A continuación se describen las decisiones tecnológicas adoptadas, organizadas por capa funcional del sistema.

6.1 Capa de datos

Para el procesamiento, limpieza y transformación de los datos se empleará **Python** como lenguaje principal, dada su consolidada posición en el ámbito del análisis de datos y la computación científica. Python ofrece un ecosistema amplio de librerías especializadas para la manipulación de datos tabulares, el análisis estadístico

exploratorio y la preparación de conjuntos de entrenamiento. Su uso en este proyecto se justifica tanto por su idoneidad técnica como por su adopción generalizada en entornos de investigación y ciencia de datos.

El conjunto de datos de referencia se almacenará en un formato estructurado compatible con las herramientas de procesamiento seleccionadas. No se contempla el uso de sistemas de gestión de bases de datos distribuidas ni de infraestructuras de procesamiento en tiempo real, en coherencia con el alcance estático del sistema.

6.2 Capa de modelado

El entrenamiento, evaluación y serialización del modelo de clasificación supervisada se realizará íntegramente en Python, haciendo uso de librerías estándar del ecosistema científico orientadas al aprendizaje automático. Estas librerías permiten la implementación de distintos algoritmos de clasificación, la evaluación mediante métricas de rendimiento y la exportación del modelo entrenado para su integración en la capa de presentación.

6.3 Capa de presentación

La interfaz de usuario se desarrollará como una aplicación web ligera que permita la introducción de variables y la visualización del resultado de clasificación. Se optará por un marco de desarrollo web de bajo peso, adecuado para prototipos funcionales de carácter académico, que facilite la integración con el modelo serializado sin requerir infraestructura compleja.

6.4 Infraestructura y reproducibilidad

Con el objetivo de garantizar la reproducibilidad del entorno de ejecución y facilitar el despliegue del sistema en distintas máquinas, se contempla la contenedorización de los componentes mediante tecnologías de virtualización ligera basadas en contenedores. Este enfoque permite aislar las dependencias del proyecto, asegurar la consistencia entre entornos de desarrollo y producción, y simplificar el proceso de puesta en marcha del sistema por parte de terceros.

6.5 Consideraciones de diseño arquitectónico

La arquitectura adoptada sigue un enfoque modular por capas, en el que cada componente tiene una responsabilidad bien delimitada. La separación entre la capa de modelado y la capa de presentación permite la sustitución o actualización futura del modelo sin necesidad de modificar la interfaz de usuario. Este desacoplamiento favorece la mantenibilidad del sistema, su escalabilidad en un contexto académico y la posibilidad de evolución incremental a lo largo del ciclo de vida del proyecto.

6.6 Tabla resumen de tecnologías seleccionadas

Tecnología	Tipo	Uso en el sistema	Motivo de elección	Alternativa descartada
Python	Lenguaje	Procesamiento de datos y modelado ML	Amplio ecosistema científico, madurez y reproducibilidad	R u otros lenguajes con menor integración web

Tecnología	Tipo	Uso en el sistema	Motivo de elección	Alternativa descartada
Librerías de ML del ecosistema Python	Librería	Entrenamiento y validación del modelo	Estándar académico en clasificación supervisada	Implementación manual desde cero
Framework web ligero	Framework	Desarrollo de la interfaz	Simplicidad y bajo acoplamiento	Framework full-stack de mayor complejidad
Dataset estructurado en formato tabular	Fuente de datos	Entrenamiento del modelo	Compatibilidad directa con algoritmos supervisados	Base de datos relacional persistente
Contenedores	Infraestructura	Reproducibilidad del entorno	Aislamiento de dependencias y consistencia entre entornos	Instalación manual local

7. Modelo de datos

El modelo de datos de GlucoCheck se articula en torno a un único dataset tabular de carácter estático, empleado exclusivamente durante las fases de entrenamiento y validación del modelo. No existe una base de datos operativa en producción ni almacenamiento persistente de datos de usuario. A continuación se describe la estructura lógica del dataset, las entidades conceptuales involucradas, la tipología de variables, las restricciones aplicables y el diccionario formal de variables.

7.1 Esquema lógico del dataset (equivalente a ER)

El conjunto de datos adopta una estructura tabular en la que cada fila representa un registro individual (un individuo observado) y cada columna corresponde a una variable clínica, biométrica o al resultado de clasificación. Esta organización es propia de los problemas de aprendizaje supervisado y no requiere transformaciones estructurales previas para su uso con los algoritmos seleccionados.

A efectos de trazabilidad interna del proyecto, cada registro dispone de un identificador técnico (`ID_registro`) de naturaleza secuencial, sin contenido clínico ni informativo. Este identificador no contiene datos personales, no permite la reidentificación de ningún individuo y se utiliza exclusivamente para referenciar registros durante las fases de preprocesamiento y validación del modelo.

El dataset de referencia empleado es un conjunto público anonimizado de uso académico, ampliamente utilizado en investigación sobre clasificación del riesgo de diabetes tipo 2. La referencia bibliográfica exacta y la fuente de acceso se fijarán durante la fase de implementación.

7.2 Entidades y relaciones (modelo equivalente)

El modelo de datos conceptual de GlucoCheck se estructura en torno a dos entidades principales:

- **Registro clínico-biométrico**: constituye la tabla principal del dataset. Cada instancia representa a un individuo descrito mediante un conjunto de variables predictoras y una etiqueta de resultado. Es la

única entidad operativa del sistema.

- **Diccionario de variables**: artefacto documental asociado al dataset que define formalmente cada variable, su tipo de dato, su categoría funcional, su descripción semántica, las restricciones de validación aplicables y las observaciones relevantes para el modelado. No es una tabla operativa del sistema, sino una referencia documental de trazabilidad metodológica.

La relación entre ambas entidades es de naturaleza conceptual 1:1: cada columna del dataset está definida y descrita en el diccionario de variables, garantizando la coherencia entre la estructura de datos y su interpretación en el modelo.

7.3 Campos principales y tipología

Las variables del dataset se clasifican en las siguientes categorías funcionales:

- **Variables continuas**: recogen mediciones fisiológicas cuantitativas que pueden tomar cualquier valor dentro de un rango clínicamente admisible. En el contexto del modelado supervisado, estas variables se normalizan o estandarizan para garantizar la convergencia del algoritmo y evitar sesgos derivados de diferencias de escala.

- **Variables discretas o de conteo**: representan frecuencias o recuentos expresados como valores enteros no negativos. Requieren un tratamiento específico durante el preprocesamiento para gestionar posibles valores atípicos o fuera de rango.

- **Variables derivadas o compuestas**: son variables calculadas a partir de la combinación o transformación de otras variables, que sintetizan información compleja en una única puntuación numérica. Su interpretación directa puede ser menos intuitiva, aunque su contribución al modelo puede ser relevante.

- **Variable objetivo**: variable binaria que indica la presencia o ausencia de diabetes tipo 2 en el individuo registrado. Constituye la etiqueta de supervisión sobre la que el modelo se entrena y evalúa. Su fiabilidad y calidad son determinantes para la validez del sistema.

7.4 Claves y restricciones

- **Clave primaria lógica**: el campo `ID_registro` actúa como identificador único de cada fila. Es de tipo entero secuencial, no contiene información personal y no permite la reidentificación de individuos.

- **Restricciones de dominio**: cada variable predictora está asociada a un rango de valores admisibles, definido a partir de criterios clínicos y estadísticos. Los valores fuera de rango se tratan durante el preprocesamiento y no son aceptados en la fase de inferencia.

- **Nulabilidad y gestión de faltantes**: el dataset puede contener valores ausentes o codificados como cero de forma impropia para determinadas variables. La estrategia de imputación o exclusión de estos registros se define durante la fase de preprocesamiento, con el objetivo de no introducir sesgos en el entrenamiento.

- **Consistencia de tipos**: todos los campos son de tipo numérico. No se admiten cadenas de texto, fechas ni identificadores nominales en el espacio de variables predictoras.

> **Nota**: el sistema únicamente admite como entrada las variables presentes en el dataset de entrenamiento. La incorporación de variables adicionales requeriría el rediseño del pipeline de modelado y el reentrenamiento completo del modelo.

7.5 Diccionario de variables

La siguiente tabla constituye el diccionario formal de variables del sistema, elaborado a partir de las variables de entrada definidas en el apartado 3.3 y la variable objetivo del modelo de clasificación.

Variable	Tipo de dato	Categoría	Descripción	Restricción / validación	Observaciones
ID_registro	Entero	Identificador técnico	Identificador único de fila, sin contenido clínico	Valor único, no nulo, no PII	Solo para trazabilidad interna; no se usa como variable predictora
Glucosa en ayunas	Numérico continuo	Continua	Concentración de glucosa en plasma en estado de ayuno	Valor positivo dentro de rango clínico admisible	Valores cero se consideran ausentes y requieren imputación
Presión arterial diastólica	Numérico continuo	Continua	Medición de la presión arterial diastólica	Valor positivo dentro de rango fisiológico	Valores cero se consideran ausentes y requieren imputación
Índice de masa corporal (IMC)	Numérico continuo	Continua	Relación entre peso y talla al cuadrado como indicador de composición corporal	Valor positivo dentro de rango admisible	Valores cero se consideran ausentes y requieren imputación
Concentración de insulina sérica	Numérico continuo	Continua	Nivel de insulina en suero medido en condiciones estándar	Valor no negativo dentro de rango clínico	Alta variabilidad; puede requerir transformación logarítmica
Grosor del pliegue cutáneo tricipital	Numérico continuo	Continua	Medición del pliegue cutáneo como estimador de masa grasa	Valor no negativo dentro de rango admisible	Valores cero se consideran ausentes y requieren imputación

Variable	Tipo de dato	Categoría	Descripción	Restricción / validación	Observaciones
Número de embarazos	Numérico discreto	Discreta / conteo	Número total de gestaciones previas registradas	Entero no negativo	Aplicable según el perfil demográfico del registro
Función de pedigrí de diabetes	Numérico continuo	Derivada / compuesta	Puntuación calculada que sintetiza la influencia del historial familiar de diabetes	Valor positivo; definido por la formulación del dataset	No tiene unidad clínica directa; su interpretación es relativa al modelo
Edad	Numérico discreto	Discreta / conteo	Edad del individuo en años completos en el momento del registro	Entero positivo dentro de rango admisible	Factor de riesgo relevante en la clasificación
Diagnóstico de diabetes (variable objetivo)	Binario	Variable objetivo	Etiqueta de resultado: indica presencia (1) o ausencia (0) de diabetes tipo 2	Valores 0 o 1 exclusivamente; no nulo	Variable de supervisión; no se utiliza como entrada en la fase de inferencia

8. Datos

8.1 Fuente y licencia

GlucoCheck emplea un dataset público anonimizado, ampliamente utilizado en investigación académica y en entornos de formación en ciencia de datos para tareas de clasificación binaria del riesgo de diabetes tipo 2. Su uso recurrente en la literatura científica avala su idoneidad como referencia metodológica para el presente proyecto.

El conjunto de datos no contiene información de identificación personal (PII) de ningún tipo. Todos los registros están anonimizados y representan exclusivamente observaciones numéricas de variables clínicas y biométricas, sin que sea posible la identificación directa o indirecta de los individuos registrados.

La referencia bibliográfica exacta, la fuente de acceso y la licencia específica de uso se confirmarán y documentarán durante la fase de implementación del proyecto, en coherencia con las condiciones de distribución del dataset seleccionado.

8.2 Naturaleza y tipología de los datos

Los datos empleados son de naturaleza clínica y biométrica, estructurados en formato tabular. Cada registro corresponde a un individuo descrito mediante un conjunto de variables predictoras numéricas y una variable objetivo binaria que indica la presencia o ausencia de diabetes tipo 2.

Los datos son de carácter estático: representan observaciones puntuales recogidas en un momento determinado y no forman parte de una serie temporal ni de un seguimiento longitudinal. No existe actualización dinámica del dataset en producción, y el sistema no incorpora mecanismos de ingesta de nuevos registros durante su operación.

8.3 Volumen y frecuencia

El dataset es de tamaño reducido, coherente con los rangos habituales de los conjuntos de datos académicos de clasificación binaria empleados en proyectos de formación e investigación aplicada. No se contempla la ampliación incremental del dataset durante el desarrollo del proyecto.

La frecuencia de actualización es nula: el dataset es un recurso cerrado, descargado en una única ocasión y utilizado exclusivamente para las fases de entrenamiento y validación interna del modelo. No se realizan actualizaciones, ingestas periódicas ni sincronizaciones con fuentes externas.

8.4 Calidad esperada

El dataset presenta características típicas de los conjuntos de datos de esta naturaleza que condicionan el proceso de preprocesamiento:

- **Valores faltantes**: determinadas variables pueden contener valores codificados como cero de forma impropia, lo que requiere su tratamiento mediante imputación o exclusión antes del entrenamiento.
- **Desbalance de clases**: es probable que la proporción de registros con diagnóstico positivo sea inferior a la de registros negativos, lo que puede afectar al rendimiento del modelo si no se aplican técnicas de compensación adecuadas.
- **Necesidad de normalización**: las variables continuas presentan escalas heterogéneas que requieren estandarización para garantizar el correcto funcionamiento de los algoritmos de clasificación seleccionados.

El tratamiento de estos aspectos se integra en el pipeline de preprocesamiento descrito en el apartado 6 y en el modelo de datos del apartado 7.

8.5 Riesgos asociados a los datos

El uso del dataset implica una serie de riesgos metodológicos que deben tenerse en cuenta en la interpretación de los resultados:

- **Sesgo de selección**: el dataset fue recopilado sobre una población específica, cuyas características demográficas y clínicas pueden no ser representativas de otras poblaciones.
- **Representatividad limitada**: la ausencia de diversidad poblacional en el conjunto de datos puede comprometer la generalización del modelo a contextos distintos del de origen.
- **Falta de variables contextuales**: el dataset no recoge información sobre hábitos de vida, medicación activa, historial clínico completo u otros factores de riesgo relevantes, lo que limita la capacidad explicativa del modelo.
- **Riesgo de extrapolación indebida**: los resultados obtenidos son válidos exclusivamente en el contexto experimental del proyecto y no deben extrapolarse a entornos clínicos reales sin validación externa adicional.

8.6 Clasificación del origen de los datos

A efectos de trazabilidad y coherencia con el marco ético y legal del proyecto, se establece la siguiente clasificación del origen de los datos empleados:

- Los datos son **reales e históricos**: fueron recogidos en condiciones clínicas reales y posteriormente anonimizados para su distribución pública con fines académicos.
- Los datos **no son simulados** ni generados sintéticamente.
- Los datos **no son mockeados** ni fabricados para el proyecto.
- El sistema **no recoge datos de usuarios reales** en ninguna de sus fases de operación. La única fuente de datos del sistema es el dataset académico descrito en este apartado, utilizado exclusivamente para entrenamiento y validación del modelo.

9. Ética, legalidad y accesibilidad

El diseño de GlucoCheck incorpora desde su fase inicial una reflexión estructurada sobre las implicaciones éticas, jurídicas y de accesibilidad derivadas del uso de modelos predictivos en un dominio con dimensión clínica. Este apartado recoge los principios y compromisos que guían el desarrollo del sistema en cada uno de estos ámbitos.

9.1 Datos personales y GDPR

GlucoCheck no realiza tratamiento de datos personales en ninguna de sus fases de desarrollo ni de operación. El dataset empleado es de carácter público y anonimizado, y no contiene información de identificación personal (PII) que permita la identificación directa o indirecta de los individuos registrados. En consecuencia, el proyecto no está sujeto a las obligaciones derivadas de la normativa de protección de datos personales en su función de responsable o encargado del tratamiento.

El sistema no almacena, registra ni monitoriza los datos introducidos por el usuario durante la fase de inferencia. Cada consulta se procesa de forma puntual y no persistente, sin que los valores introducidos sean retenidos, registrados en logs ni transmitidos a sistemas externos. No existe base de datos operativa de usuarios ni mecanismo alguno de seguimiento de sesiones o perfiles.

9.2 Riesgos éticos del uso de modelos predictivos

El uso de modelos de clasificación supervisada en contextos con dimensión clínica conlleva riesgos éticos que deben ser reconocidos explícitamente:

- **Sobreinterpretación diagnóstica**: existe el riesgo de que el usuario interprete el nivel de riesgo asignado como un diagnóstico médico. Este riesgo es inherente a cualquier herramienta analítica en el ámbito sanitario y se mitiga mediante advertencias explícitas y una delimitación rigurosa del alcance del sistema.
- **Automatización indebida de decisiones**: el sistema no debe emplearse como base única para la toma de decisiones clínicas, administrativas o terapéuticas. Su función es estrictamente analítica y de apoyo a la comprensión de patrones de riesgo.
- **Sesgos por composición del dataset**: el modelo aprende a partir de un conjunto de datos con una composición poblacional específica. Variables demográficas o clínicas insuficientemente representadas pueden introducir sesgos sistemáticos que afecten al rendimiento del sistema en determinados subgrupos, sin que el modelo los detecte por sí mismo.
- **Falsa sensación de precisión**: la presentación de un resultado categorizado puede generar en el usuario una percepción de exactitud superior a la real. El sistema debe comunicar sus resultados con el

grado de incertidumbre que les corresponde, evitando representaciones que induzcan una confianza injustificada.

9.3 Medidas de mitigación

Para reducir los riesgos éticos identificados, el sistema adopta las siguientes medidas:

- **Advertencias explícitas en la interfaz**: el sistema incorpora avisos visibles que recuerdan al usuario que los resultados no constituyen un diagnóstico médico y que no deben utilizarse como base para decisiones clínicas, conforme a lo establecido en el apartado 3.5.
- **Delimitación clara del alcance académico**: toda la documentación del proyecto, incluida la interfaz, refuerza de forma consistente que GlucoCheck es una herramienta académica con fines analíticos y formativos.
- **Transparencia metodológica**: se documenta el proceso de entrenamiento, validación y umbralización del modelo, de forma que cualquier evaluador pueda comprender el origen y las limitaciones de los resultados.
- **No integración en flujos clínicos reales**: el sistema no se conecta a sistemas de información sanitaria, historias clínicas electrónicas ni ningún otro entorno asistencial real.
- **Requisito de validación externa**: cualquier uso del sistema o del modelo en un contexto aplicado fuera del entorno académico requeriría un proceso de validación externa independiente, análisis de equidad y revisión regulatoria previa.

9.4 Accesibilidad digital

El diseño de la interfaz de usuario se orienta a garantizar la comprensibilidad de los resultados y la accesibilidad básica del sistema, aplicando los siguientes principios:

- **Principios WCAG básicos**: la interfaz se diseña conforme a los principios de perceptibilidad, operabilidad, comprensibilidad y robustez establecidos en las pautas de accesibilidad para el contenido web, en su nivel de conformidad básico.
- **Contraste adecuado**: los elementos visuales, incluidos los indicadores de nivel de riesgo, utilizarán combinaciones de color con contraste suficiente para garantizar su legibilidad en condiciones normales de uso.
- **Lenguaje claro**: los mensajes dirigidos al usuario se redactan en lenguaje no técnico, evitando terminología clínica o estadística que pueda dificultar la comprensión del resultado.
- **Ausencia de visualizaciones ambiguas**: se evitan representaciones gráficas que puedan ser malinterpretadas o que induzcan conclusiones erróneas sobre el nivel de riesgo asignado.
- **Diseño orientado a la comprensión**: la interfaz prioriza la transmisión clara y honesta de la información sobre cualquier criterio estético o persuasivo, en coherencia con el carácter académico y la dimensión ética del proyecto.

10. Backlog inicial

El backlog inicial de GlucoCheck se articula mediante historias de usuario que recogen las funcionalidades del sistema desde la perspectiva de quienes interactúan con él. Las historias se organizan por prioridad y cada una incluye criterios de aceptación verificables técnicamente.

10.1 Alta prioridad

Historia 1: Como Data Engineer, quiero cargar y preprocesar el dataset público anonimizado, para obtener un conjunto de datos limpio, coherente y listo para el entrenamiento del modelo.

Criterios de aceptación:

- El pipeline lee el dataset en formato tabular y verifica la integridad estructural de las columnas esperadas.
- Los valores ausentes o codificados de forma impropia son detectados e imputados o excluidos conforme a la estrategia definida.
- El dataset preprocesado contiene únicamente las variables definidas en el diccionario del apartado 7.5, sin columnas adicionales.

Historia 2: Como ML Engineer, quiero entrenar un modelo de clasificación supervisada sobre el dataset preprocesado, para obtener un clasificador capaz de estimar la probabilidad de riesgo de diabetes tipo 2.

Criterios de aceptación:

- El modelo se entrena utilizando únicamente las variables predictoras definidas en el diccionario de variables, excluyendo la variable objetivo del espacio de entrada.
- El proceso de entrenamiento finaliza sin errores y genera un artefacto serializado del modelo listo para su integración.
- El modelo produce una probabilidad estimada continua entre 0 y 1 para cada registro de entrada.

Historia 3: Como ML Engineer, quiero validar el rendimiento del modelo mediante particiones diferenciadas y métricas estándar, para garantizar la solidez estadística del clasificador antes de su integración.

Criterios de aceptación:

- El proceso de validación emplea subconjuntos diferenciados de entrenamiento y evaluación sin solapamiento.
- Se calculan y documentan al menos las métricas de sensibilidad, especificidad y área bajo la curva ROC.
- Los resultados de validación son reproducibles ante la misma semilla de partición del dataset.

Historia 4: Como ML Engineer, quiero definir los umbrales de categorización del riesgo sobre la probabilidad estimada, para que el sistema clasifique correctamente en tres niveles: bajo, moderado y alto.

Criterios de aceptación:

- Los umbrales se determinan a partir del análisis de la curva ROC y priorizan la minimización de falsos negativos en el nivel alto.
- La aplicación de los umbrales al conjunto de validación produce exactamente tres categorías de salida: bajo, moderado y alto.
- Los umbrales y su justificación quedan documentados en el artefacto de modelado.

Historia 5: Como usuario de la interfaz, quiero introducir los valores de las variables clínicas y biométricas a través de un formulario web, para obtener la clasificación de riesgo correspondiente sin necesidad de instalar software adicional.

Criterios de aceptación:

- El formulario contiene un campo de entrada por cada variable definida en el apartado 3.3, con etiqueta descriptiva.
- El sistema valida que todos los campos están rellenos y que los valores se encuentran dentro del rango admisible antes de enviar la solicitud al backend.
- Los errores de validación se comunican al usuario de forma clara e individualizada por campo.

Historia 6: Como usuario de la interfaz, quiero visualizar el resultado de clasificación de forma clara e interpretable, para comprender el nivel de riesgo asignado sin ambigüedad.

Criterios de aceptación:

- El resultado muestra el nivel de riesgo categorizado (bajo, moderado o alto) con su color indicativo (verde, amarillo, rojo).
- La interfaz incluye un aviso visible que recuerda que el resultado no constituye un diagnóstico médico.
- El resultado se presenta en menos de tres segundos desde el envío del formulario.

10.2 Prioridad media

Historia 7: Como DevOps, quiero contenedorizar todos los componentes del sistema, para garantizar la reproducibilidad del entorno de ejecución en distintas máquinas.

Criterios de aceptación:

- Cada componente del sistema (capa de datos, backend y frontend) dispone de su propia definición de contenedor.
- El sistema arranca completamente a partir de un único comando de orquestación sin configuración manual adicional.
- El entorno contenedorizado produce resultados idénticos a los obtenidos en el entorno de desarrollo local.

Historia 8: Como usuario de la interfaz, quiero que el sistema valide las entradas en el lado del cliente antes de enviarlas, para recibir retroalimentación inmediata sin necesidad de esperar la respuesta del servidor.

Criterios de aceptación:

- Los campos numéricos rechazan entradas no numéricas con un mensaje de error visible.
- Los campos con restricciones de rango informan al usuario cuando el valor introducido está fuera del dominio admisible.
- El formulario no puede enviarse si existe al menos un campo inválido o vacío.

Historia 9: Como ML Engineer, quiero incorporar una representación visual del peso relativo de las variables en la clasificación, para mejorar la interpretabilidad del resultado y facilitar su comprensión por parte del usuario.

Criterios de aceptación:

- La interfaz muestra una representación gráfica de la contribución relativa de las variables al resultado de clasificación.
- La visualización es coherente con el modelo serializado utilizado en inferencia.
- La representación no induce interpretaciones causales ni diagnósticas.

10.3 Prioridad baja

Historia 10: Como ML Engineer, quiero comparar el rendimiento de distintos algoritmos de clasificación supervisada sobre el mismo dataset, para seleccionar el modelo con mejor equilibrio entre capacidad discriminativa y estabilidad.

Criterios de aceptación:

- Se evalúan al menos dos algoritmos distintos bajo las mismas condiciones de partición y métricas.
- Los resultados comparativos quedan documentados en un artefacto técnico del proyecto.
- El algoritmo seleccionado se justifica explícitamente a partir de los resultados obtenidos.

Historia 11: Como Frontend / BI, quiero que la interfaz cumpla los principios básicos de accesibilidad digital, para garantizar que el sistema sea comprensible y utilizable por el perfil de usuario definido.

Criterios de aceptación:

- Los elementos de resultado utilizan combinaciones de color con contraste suficiente según los criterios WCAG básicos.
- Los mensajes del sistema están redactados en lenguaje no técnico y no incluyen terminología clínica sin explicación.
- El sistema no emplea visualizaciones que puedan ser malinterpretadas como indicadores de certeza clínica.

Historia 12: Como equipo de desarrollo, quiero documentar el pipeline de modelado de forma técnica y reproducible, para que cualquier evaluador pueda verificar el proceso de entrenamiento y validación de forma independiente.

Criterios de aceptación:

- La documentación describe cada etapa del pipeline: carga, preprocesamiento, entrenamiento, validación y serialización.
- Los parámetros relevantes del modelo y los umbrales de clasificación quedan registrados en el repositorio del proyecto.
- Un evaluador externo puede reproducir el proceso completo a partir de la documentación y el repositorio sin intervención del equipo.

La organización del backlog responde a un enfoque iterativo e incremental, que permite desarrollar el sistema por fases funcionales claramente delimitadas y facilita la validación progresiva de cada componente antes de su integración completa. Este planteamiento contribuye a reducir riesgos técnicos, mejorar la trazabilidad del desarrollo y asegurar la coherencia entre los objetivos académicos y la implementación efectiva del sistema.

11. Plan de trabajo

El plan de trabajo organiza el desarrollo de GlucoCheck en fases secuenciales con validación incremental, coherentes con el backlog definido y la estrategia iterativa del proyecto. Cada fase contempla actividades concretas, un entregable verificable y responsables asignados.

11.1 Cronograma por semanas

Semana	Fase	Actividades principales	Entregable verificable
1	Preparación y análisis	Descarga y revisión estructural del dataset; verificación de variables, tipos y coherencia con el diccionario; análisis exploratorio inicial; configuración del entorno de trabajo	Dataset validado, entorno configurado y análisis exploratorio documentado
2	Preprocesamiento	Detección y tratamiento de valores faltantes; normalización de variables continuas; gestión del desbalance de clases; partición en subconjuntos de entrenamiento y evaluación	Pipeline de preprocesamiento funcional y dataset listo para modelado
3	Modelado y validación	Entrenamiento del modelo de clasificación supervisada; evaluación mediante métricas (sensibilidad, especificidad, ROC); ajuste de parámetros; definición y justificación de umbrales	Modelo entrenado, evaluado, con umbrales definidos y artefacto serializado
4	Integración y backend	Desarrollo del backend de inferencia; integración del modelo serializado; exposición de endpoint para recepción de variables y devolución de resultado categorizado	Backend funcional con integración del modelo verificada
5	Desarrollo de interfaz	Desarrollo del formulario web de entrada; visualización del resultado de clasificación; implementación de advertencias de alcance; validación de entradas en cliente	Prototipo funcional completo y operativo dentro del alcance definido
6	Pruebas y documentación	Pruebas de integración entre componentes; verificación de coherencia del sistema; elaboración de documentación técnica y académica definitiva; revisión de cumplimiento ético y legal	Sistema validado, documentación completa y repositorio entregable

11.2 Hitos principales

Los siguientes hitos constituyen puntos de control del proyecto, con criterios de verificación objetivos:

- **Hito 1 — Dataset validado** *(fin de semana 2)*: el dataset ha sido cargado, analizado y preprocesado. El pipeline genera un conjunto de datos limpio, coherente con el diccionario de variables y listo para el entrenamiento. Criterio de verificación: el pipeline ejecuta sin errores y el dataset de salida contiene exclusivamente las variables definidas en el apartado 7.5.

- **Hito 2 — Modelo entrenado y evaluado** *(fin de semana 3)*: el modelo de clasificación supervisada ha sido entrenado, validado y documentado. Los umbrales de categorización están definidos y justificados. Criterio de verificación: existe un artefacto serializado del modelo y un registro documentado de las métricas de validación.

- **Hito 3 — Prototipo funcional** *(fin de semana 5)*: el sistema integra pipeline, modelo e interfaz de forma operativa. El usuario puede introducir variables, obtener una clasificación y visualizar el resultado con sus advertencias correspondientes. Criterio de verificación: el prototipo responde correctamente a entradas válidas e inválidas sin errores en los tres componentes.

- **Hito 4 — Documentación completa y entrega final** *(fin de semana 6)*: toda la documentación técnica y académica está finalizada, el repositorio está ordenado y el sistema cumple los requisitos de alcance, ética y accesibilidad definidos. Criterio de verificación: la documentación cubre todos los apartados de la memoria técnica y el repositorio es reproducible por un evaluador externo.

11.3 Dependencias técnicas

El desarrollo del proyecto presenta las siguientes dependencias secuenciales que condicionan el orden de ejecución de las tareas:

- **El preprocesamiento depende de la validación del dataset**: no es posible iniciar el entrenamiento del modelo sin haber completado la limpieza, imputación y partición del dataset, ya que un dataset mal preprocesado invalidaría los resultados del modelo.
- **El entrenamiento depende del preprocesamiento**: el pipeline de modelado requiere como entrada el dataset procesado y particionado. Cualquier modificación del preprocesamiento implica reentrenamiento del modelo.
- **La definición de umbrales depende del entrenamiento y la validación**: los umbrales de categorización se determinan a partir del análisis de la curva ROC del modelo entrenado y no pueden fijarse con anterioridad.
- **La integración del backend depende de la serialización del modelo**: el componente de inferencia no puede desarrollarse sin disponer del artefacto serializado del modelo validado.
- **El desarrollo de la interfaz depende del backend operativo**: la capa de presentación requiere un endpoint funcional al que enviar los datos de entrada y del que recibir el resultado categorizado.
- **Las pruebas de integración dependen de todos los componentes**: la validación integral del sistema solo puede ejecutarse una vez que pipeline, modelo, backend e interfaz están operativos de forma independiente.

11.4 Reparto de responsabilidades

Rol	Responsable	Tareas asignadas
Data Engineer	Markel	Descarga y análisis del dataset; diseño e implementación del pipeline de preprocesamiento; validación de la coherencia entre datos de entrenamiento y datos de inferencia

Rol	Responsable	Tareas asignadas
ML Engineer	Steven	Entrenamiento y evaluación del modelo; definición de umbrales; documentación de métricas; serialización del artefacto del modelo
DevOps	Juan Carlos	Configuración del entorno de trabajo; contenedorización de componentes; integración entre capas; pruebas de sistema y verificación de reproducibilidad
Frontend / BI	Miguel Ángel	Desarrollo del formulario web de entrada; implementación de la visualización del resultado; integración de advertencias de alcance; cumplimiento de criterios de accesibilidad

11.5 Riesgos técnicos vinculados al plan

Los riesgos técnicos identificados en el apartado 13 tienen impacto directo sobre el cronograma y deben gestionarse de forma activa durante el desarrollo:

- **Riesgo de sobreajuste del modelo** *(semana 3)*: si el modelo presenta un rendimiento excesivamente optimista en el subconjunto de entrenamiento y deteriorado en el de evaluación, será necesario revisar los parámetros, la estrategia de validación cruzada o el preprocesamiento antes de avanzar al hito 2. Este riesgo puede generar una iteración adicional no prevista entre las semanas 2 y 3.
- **Riesgo de retrasos en validación** *(semanas 3–4)*: si los resultados de validación no alcanzan los criterios metodológicos definidos, el hito 2 podría retrasarse e impactar en el inicio de la fase de integración. La estrategia de mitigación contempla el retorno controlado a fases anteriores conforme a lo establecido en el apartado 11.
- **Riesgo de integración entre componentes** *(semana 4–5)*: la integración del modelo serializado en el backend y la comunicación entre backend e interfaz pueden introducir inconsistencias no detectadas en fases anteriores. Se mitiga mediante la validación independiente de cada componente antes de su integración, conforme al apartado 12.3.

La planificación descrita no se entiende como un proceso estrictamente lineal, sino como un marco estructurado susceptible de iteración controlada. En caso de que los resultados obtenidos en la fase de validación no alcancen los criterios metodológicos definidos, se contempla el retorno a fases anteriores para ajustar el modelo o revisar el preprocesamiento de datos. Este enfoque refuerza la robustez del desarrollo y permite una gestión proactiva de riesgos técnicos.

12. Estrategia de desarrollo

La estrategia de desarrollo de GlucoCheck se fundamenta en un enfoque iterativo e incremental, alineado con el backlog definido y el plan de trabajo establecido. Este apartado describe los principios, flujos de trabajo y mecanismos de control que guían el desarrollo del sistema desde la preparación de datos hasta la entrega final.

12.1 Modelo de ciclo de vida

El ciclo de vida del proyecto se estructura bajo un enfoque iterativo e incremental. El desarrollo se organiza en iteraciones sucesivas, cada una de las cuales abarca una o varias fases funcionales (preparación de datos, modelado, integración, validación) y genera un incremento verificable antes de avanzar a la siguiente.

Al final de cada incremento se realiza una revisión de los entregables producidos, verificando que cumplen los criterios de aceptación definidos en el backlog. Si los resultados no alcanzan los criterios establecidos, se contempla el retorno controlado a la fase anterior para ajustar el componente afectado sin comprometer el resto del sistema. Este enfoque reduce la acumulación de deuda técnica y permite una gestión proactiva de los riesgos identificados en el apartado 13.

12.2 Flujo Git

El control de versiones del proyecto se gestiona mediante un repositorio Git con la siguiente estructura de ramas:

- `main`: rama estable que contiene únicamente versiones validadas y revisadas del sistema. No se permite ningún commit directo sobre esta rama. Las incorporaciones a `main` se realizan exclusivamente mediante pull request aprobada por al menos un miembro del equipo distinto al autor.
- `develop`: rama de integración continua donde se consolidan los incrementos funcionales una vez validados de forma independiente. Actúa como entorno de preproducción interno del proyecto.
- `feature/*`: ramas de trabajo individual creadas a partir de `develop` para el desarrollo de cada funcionalidad o tarea del backlog. Su nomenclatura sigue el patrón `feature/descripcion-breve`. Una vez completada la tarea y verificados sus criterios de aceptación, se integran en `develop` mediante pull request.

El proceso de pull request incluye una revisión mínima por parte de otro miembro del equipo, verificación de que no se introduce código que rompa funcionalidades existentes, y comprobación de que el entregable es coherente con el alcance definido. No se fusionan ramas que contengan conflictos no resueltos o criterios de aceptación incumplidos.

12.3 Integración del código

La integración entre los distintos componentes del sistema se realiza de forma progresiva, siguiendo el orden de dependencias técnicas establecido en el apartado 11.3:

- Cada componente (pipeline de datos, modelo, backend, interfaz) se desarrolla y valida de forma independiente en su rama `feature` correspondiente antes de ser integrado en `develop`.
- El modelo serializado debe estar disponible y verificado antes de iniciar el desarrollo del backend de inferencia. No se desarrolla la integración sobre un modelo no validado.
- La integración entre backend e interfaz se realiza únicamente cuando ambos componentes han superado su validación independiente.
- Cualquier modificación del pipeline de preprocesamiento tras la serialización del modelo implica el reentrenamiento y la nueva validación del modelo antes de continuar con la integración.

12.4 Validación funcional

La validación funcional del sistema se realiza mediante revisión manual de las historias de usuario definidas en el backlog, comprobando que cada criterio de aceptación es satisfecho antes de cerrar la historia correspondiente.

El proceso de validación incluye:

- **Verificación individual por historia**: el responsable de la tarea comprueba cada criterio de aceptación de forma explícita y documentada antes de abrir la pull request.

- **Revisión cruzada entre roles**: un miembro del equipo con rol distinto al autor revisa el incremento desde la perspectiva de su capa funcional, identificando posibles incoherencias entre componentes.
- **Comprobación de criterios de aceptación del backlog**: ninguna historia se cierra como completada si existe al menos un criterio de aceptación no satisfecho o no verificable en el estado actual del sistema.

12.5 Testing básico

El proyecto contempla una estrategia de testing mínima orientada a garantizar la corrección de los componentes críticos y la reproducibilidad del sistema:

- **Tests unitarios para el pipeline**: se verifican las funciones críticas del pipeline de preprocesamiento, incluyendo la detección de valores faltantes, la transformación de variables y la generación del conjunto de entrenamiento y evaluación.
- **Test de inferencia sobre ejemplo controlado**: se define un conjunto de entradas con resultado esperado conocido para verificar que el modelo serializado devuelve la categorización correcta tras la integración en el backend.
- **Test de integración backend–frontend**: se verifica que el flujo completo —desde la introducción de variables en el formulario hasta la visualización del resultado categorizado— funciona sin errores en el entorno integrado.
- **Verificación de reproducibilidad en entorno contenedorizado**: el sistema debe producir resultados idénticos en el entorno contenedorizado y en el entorno de desarrollo local, confirmando que la contenedorización no introduce discrepancias en el comportamiento del modelo.

13. Riesgos técnicos actualizados

El desarrollo de GlucoCheck implica una serie de riesgos técnicos inherentes a los proyectos basados en modelos de aprendizaje automático. La siguiente tabla recoge los riesgos identificados, su caracterización y el plan de mitigación asociado, en coherencia con la estrategia de desarrollo del apartado 12 y el plan de trabajo del apartado 11.

Riesgo	Descripción técnica	Impacto	Probabilidad	Plan de mitigación

Riesgo	Descripción técnica	Impacto	Probabilidad	Plan de mitigación
Sobreajuste del modelo	El modelo aprende patrones específicos del subconjunto de entrenamiento que no se generalizan al subconjunto de evaluación, reduciendo su utilidad predictiva sobre datos no observados y comprometiendo la validez del sistema.	Alto	Media	Aplicar validación cruzada para estimar el rendimiento de forma robusta. Comparar métricas entre subconjuntos de entrenamiento y evaluación. Si la brecha es significativa, revisar parámetros del modelo o estrategia de preprocesamiento antes de cerrar el hito 2 (apartado 11.2).
Desbalance de clases	El dataset presenta una proporción significativamente menor de registros con diagnóstico positivo respecto a los negativos, lo que puede sesgar el modelo hacia la clase mayoritaria y reducir la sensibilidad en el nivel de riesgo alto.	Alto	Alta	Evaluar la distribución de clases durante el análisis exploratorio (semana 1). Aplicar técnicas de compensación de desbalance durante el preprocesamiento. Priorizar métricas de sensibilidad y especificidad frente a la exactitud global en la evaluación del modelo.

Riesgo	Descripción técnica	Impacto	Probabilidad	Plan de mitigación
Dependencia del dataset específico	El modelo se entrena exclusivamente sobre un dataset público con una composición poblacional concreta. Su rendimiento puede degradarse ante perfiles clínicos o demográficos no representados en dicho conjunto, limitando la generalización del sistema.	Alto	Alta	Documentar explícitamente las características del dataset y los límites de generalización del modelo. Incluir esta restricción en las advertencias de la interfaz y en el alcance del sistema (apartado 4.2). Cualquier extensión del sistema a nuevas poblaciones requeriría validación externa adicional.
Deriva del modelo en escenarios extendidos	En un contexto de uso prolongado o con incorporación de nuevos datos, la distribución de las variables de entrada podría cambiar respecto a la del entrenamiento, reduciendo progresivamente la validez predictiva del modelo sin que el sistema lo detecte de forma automática.	Medio	Baja	Dado que el proyecto no contempla explotación en producción real, este riesgo se gestiona mediante documentación explícita de la limitación. Para cualquier uso extendido futuro, se establece como requisito la implementación de mecanismos de monitorización del rendimiento y recalibración periódica.

Riesgo	Descripción técnica	Impacto	Probabilidad	Plan de mitigación
Fallos de integración entre componentes	La separación modular entre pipeline de datos, modelo y capa de presentación puede introducir inconsistencias en la comunicación entre componentes, especialmente en la transmisión del artefacto serializado al backend y en el contrato de entrada/salida entre backend e interfaz.	Medio	Media	Validar cada componente de forma independiente antes de su integración, conforme al apartado 12.3. Definir y documentar el contrato de entrada/salida del endpoint de inferencia antes de iniciar el desarrollo de la interfaz. Ejecutar el test de integración backend–frontend definido en el apartado 12.5.
Problemas de reproducibilidad	Diferencias en versiones de dependencias o en la configuración del entorno entre los distintos miembros del equipo pueden producir resultados inconsistentes entre máquinas, dificultando la verificación y evaluación del sistema por parte de terceros.	Medio	Media	Contenedorizar todos los componentes del sistema conforme al apartado 12.5. Fijar las dependencias del entorno en el repositorio del proyecto. Verificar que el sistema produce resultados idénticos en el entorno contenedorizado y en los entornos locales de desarrollo antes de cerrar el hito 4 (apartado 11.2).

En conjunto, la gestión activa de estos riesgos técnicos contribuye a reforzar la robustez del proyecto y su coherencia con el marco académico y metodológico definido.

14. Repositorio del proyecto

El código fuente, la documentación técnica y los artefactos generados durante el desarrollo del proyecto se gestionan a través de un repositorio de control de versiones. Este repositorio centraliza los distintos componentes del sistema, incluyendo el pipeline de datos, el modelo de clasificación y la capa de presentación.

La estructura del repositorio se organiza de forma modular, diferenciando claramente los directorios correspondientes a datos, modelado, interfaz y documentación. Esta organización facilita la mantenibilidad del proyecto y permite una navegación clara entre los distintos elementos que lo componen.

Cada actualización relevante del sistema se registra mediante un sistema de versionado que permite rastrear cambios, recuperar estados anteriores y garantizar la trazabilidad de las decisiones técnicas adoptadas durante el desarrollo. Esta práctica contribuye a reforzar la reproducibilidad del proyecto y su coherencia metodológica.

El repositorio constituye, por tanto, el soporte técnico que consolida el proyecto como artefacto académico reproducible, transparente y verificable por terceros dentro del marco definido en la presente memoria.